



Text-to-SQL pipeline


Xây dựng & đánh giá hệ thống Retrieval cho Text-to-SQL

- Document → Knowledge Base
- Hybrid Retrieval
- Evaluation




01 HYBRID RAG

Dense vectors meet sparse keywords.



02 GRAPH RAG

Answers live in the relationships.



Phase 1 - Parse (Document to Markdown)

Đọc file và chuyển thành Markdown sạch

- **input:** .docx, .pdf, .xlsx từ data/raw/sql
- tạo doc_id: slug, bỏ dấu, giữ đuôi
- docling cho PDF, MarkitDown/Mammoth cho DOCX, openpyxl cho XLSX
- Pipeline phục hồi cấu trúc heading hierarchy và xử lý bảng nhiều trang trong PDF
- **Output:** data/processed/sql/p<project>/<doc_id>.md

Phase 2 - Extract (Markdown to Structure)

Tách Markdown thành các element có role

● **Parser: markdown-it-py**

Không dùng regex — parser CommonMark nhanh nhất, hỗ trợ bảng GFM và gạch ngang.
Quy trình: phát hiện → xác thực → token hóa.

Python | CommonMark | GFM

● **Block → Element với ID**

Mỗi block Markdown được tách thành Element riêng, gán mã định danh duy nhất để truy xuất trong toàn bộ pipeline.

Unique ID | AST-based

● **Đầu ra: <doc_id>.extract.json**

Mỗi tài liệu đầu ra một tệp JSON với cấu trúc Elements đã gán vai trò, sẵn sàng cho giai đoạn Embedding.

JSON | Structured

Role	Description
table_meaning	Ý nghĩa của bảng trong ngữ cảnh nghiệp vụ
column_intro	Giới thiệu chi tiết từng cột và kiểu dữ liệu
business_rule	Quy tắc nghiệp vụ áp dụng trên dữ liệu
sql_sample	Code SQL
sample_query	Mẫu câu hỏi bằng ngôn ngữ tự nhiên
sample_evidence	Bảng chứng mẫu từ dữ liệu thực tế

Extract

Heading | Table | Text / Role

```
{
  "block_id": "block_4",
  "modality": "table",
  "text": "| **Tên cột** | **Kiểu dữ liệu** | **Mô tả** |\n| --- | --- | --- |\n| USER_NAME | VARCHAR2 | Mã user (ví dụ",
  "columns": [
    "Tên cột",
    "Kiểu dữ liệu",
    "Mô tả"
  ],
  "rows": [
    [
      "USER_NAME",
      "VARCHAR2",
      "Mã user (ví dụ: HUY.NGUYEN)"
    ],
    [
      "USER_ID",
      "NUMBER",
      "Mã định danh user"
    ],
    [
      "PRECINCT_CODE",
      "VARCHAR2",
      "Mã phường/xã mà user được truy cập (ví dụ: VTAU)"
    ],
    [
      "PRECINCT_NAME",
      "VARCHAR2",
      "Tên phường/xã mà user được truy cập (ví dụ: Phường Vũng Tàu)"
    ],
    [
      "HUB_CODE",
      "VARCHAR2",
      "Hub quản lý (mã hub) của phường/xã mà user được truy cập (ví dụ: VT.1)"
    ]
  ]
}
```


Phase 3 - Link (Elements to Hierarchy)

Gắn quan hệ cha-con và section/table



attach_hierarchy() stack-based

Giống như DOM parsing, mỗi phần tử mở push vào stack, đóng pop ra để xây cây.



Output: <doc_id>.linked.json

File JSON chứa cây liên kết hoàn chỉnh sẵn sàng cho bước xử lý tiếp theo.



merge_standalone_labels()

Nhãn không cha được ghép vào nội dung gần nhất để hoàn thiện cấu trúc.



Warning system phát hiện bất thường

Cảnh báo cấu trúc bất thường như vòng lặp hoặc thiếu quan hệ cha-con.

Phase 4 - Chunk (Elements to Chunks)

Chia nội dung thành đơn vị tìm kiếm

Chế độ General

MODE parent-child: match children, return parents

general parent_child

LEVEL 1 · HEADING one level-N heading = one chunk

☒ enabled 1

LEVEL 2 · TABLE_ROW long tables → group rows, repeat header

☐ enabled 10 0

LEVEL 3 · LENGTH final fallback; separate delimiters with |

☒ enabled ||. | |

BUDGET unit · maximum · minimum · overlap

token char 4000 120 0

OVER MAXIMUM truncate is the only strict guarantee

descend keep truncate

UNDER MINIMUM merge combines adjacent chunks in the same section

keep merge drop

Chế độ Parent-Child

Parent chunk settings
Parent chunks are returned to the chatbot after a child chunk matches the query.

PARENT METHOD paragraph or the entire document

paragraph full_doc

UNIT used to measure parent length

token char

HEADING LEVEL defines each parent section

2

PARENT BUDGET maximum · minimum · overlap

4096 0 0

PARENT OVER MAXIMUM


descend keep truncate

PARENT UNDER MINIMUM

keep merge drop


output: .chunks.jsonl (danh sách chunks) &
.parents.jsonl (quan hệ parent-child)

Entity & Relationship Extraction




- Take chunks (text segments) as input
- Extract entities and relationships via LLM with the format:
 - “entities”: [{"name": "string", "type": "string", "description": "string"}]
 - “relationships”: [{"source": "string", "target": "string", "description": "string"}]
- Pass the extracted entities and relationships through a reflector alongside the text chunks to verify
- Output:
 - raw_entities.csv: List of all entities
 - raw_relationships.csv: List of all relationships

Entity Resolution




- Take raw_entites.csv as input
- Normalized the name of each entities
- Group them by their normalized name
- Conactate the descriptions attached to each instance of the entity, if the final description is too long put it through an LLM to do summarization
- Output: resolved_entities.csv

Index Graph



- Take raw_relationships.csv and resolved_entities.csv as input
- Build a basic graph where:
 - 1 node = 1 entity
 - 1 edge = 1 relationship
- Pass them through the hierachical Leiden algorithm to get hierachical communities
- Pass each community bottom up into an LLM to generate community reports
- Output: node_community_membership.csv, community_graph.gexf, hierarchical_community_reports.csv


Global Query



- Group community reports randomly into chunks (based on llm token limit)
- Push each chunk into an LLM with the user query and ask it to generate:
 - An extraction and analysis of the community reports within the chunk
 - A scoring of how helpful the information is for answering the user query
- Set a helpfulness score benchmark and filter out any local answers that scores below that
- Send the remaining local answers into an LLM to synthesize the final global answer


Phase 5 - Embed (Chunks to Vector)

Chuyển chunk thành dense vector



Phase 6 - Index (Vector Store)

Lưu dense, BM25 và metadata vào Qdrant



Phase 7 - Verify

(Validation & Evaluation)

Kiểm tra artifact và index
có đồng bộ không
Đo khả năng tìm đúng và
đủ bản

RECALL METRICS

docs@5 ~0.67-0.71

sql@3 ~0.88

67-71% of relevant docs retrieved in top 5; 88% of relevant SQL queries in top 3.

Dev: 33 cases | Test: 14 valid cases

$$Score = \frac{RecallDocs@5 + RecallSQL@3}{2}$$

FINAL SCORE

~0.78-0.80 .

A 5% improvement in recall@5 directly reduces wrong answers in deployed RAG systems.

Phase 7 - Verify (Validation & Evaluation)

Mode	rrf_k	w dense/sp	docs@5	sql@3	ĐIỂM
rrf	server	—	0.674	0.965	0.819
wrrf	1	0.5/0.5	0.684	0.98	0.832
wrrf	5	0.5/0.5	0.674	0.98	0.827
wrrf	5	0.1/0.9	0.694	0.944	0.819
wrrf	20	0.3/0.7	0.664	0.965	0.814
wrrf	60	0.3/0.7	0.664	0.965	0.814
wrrf	60	0.7/0.3	0.643	0.949	0.796

Dev

Cấu hình	Dự án	docs@5	sql@3	ĐIỂM
A — rrf_k=1, 0.5/0.5	1 (DOCX)	0.708	0.881	0.795
A — rrf_k=1, 0.5/0.5	2 (PDF)	0.673	0.881	0.777
B — rrf_k=60, 0.3/0.7	1 (DOCX)	0.667	0.881	0.774
B — rrf_k=60, 0.3/0.7	2 (PDF)	0.667	0.881	0.774

Test

RECALL METRICS

docs@5 ~0.67-0.71

sql@3 ~0.88

67-71% of relevant docs retrieved in top 5; 88% of relevant SQL queries in top 3.

Dev: 33 cases | Test: 14 valid cases

$$Score = \frac{RecallDocs@5 + RecallSQL@3}{2}$$

FINAL SCORE

~0.78-0.80 .

A 5% improvement in recall@5 directly reduces wrong answers in deployed RAG systems.

Hạn chế và Hướng phát triển

Hạn chế

Hierarchy phụ thuộc vị trí Element

Không phân tích cấu trúc logic tài liệu

Qdrant-only vector stores

Chưa hỗ trợ các hệ thống vector khác như Pinecone, Weaviate

Phát triển

Tích hợp GraphRAG

Multi-hop reasoning cho truy vấn phức tạp, kết nối tri thức liên quan

Tối ưu chunking động

Token-aware chunking để tối ưu độ dài và ngữ cảnh

Hỗ trợ đa ngôn ngữ

Mở rộng embedding và parsing cho nhiều ngôn ngữ khác

Cải thiện với phản hồi người dùng

Feedback loop để tinh chỉnh kết quả tìm kiếm và chunking



Home

Projects

Settings

Help

Get Support

Log Out

Projects

Each project contains its own chatbot and knowledge bases. You can create multiple projects to manage different chatbots and knowledge bases.

Create Project

Project Name

Short Description

What does this chatbot answer questions about?

Create a new project

Each project contains its own chatbot and knowledge bases.

PROJECT NAME

test

SHORT DESCRIPTION (optional)

What does this chatbot answer questions about?

Cancel

Create project